

Predicción de etapas del sueño a partir de datos de presión y movimiento en cama, temperatura y sonido registradas en la noche

Proyecto Fundamentos de Deep learning

Susana Mejía Echeverry

1. Contexto

Los ritmos diarios de sueño y vigilia son relevantes para la salud y el sueño, por lo que monitorearlos se ha convertido en un tema de interés médico y social debido a su relación con la salud mental y física. Algunos estudios han demostrado que la insuficiencia del sueño puede causar diabetes, hipertensión, depresión o ansiedad [1]. Debido a la repercusión que tienen los trastornos del sueño en la calidad de vida humana, se han creado variedad de metodologías para estudiarlos; no obstante, estos análisis suelen realizarse en laboratorios especializados que resultan costosos, incómodos (especialmente para los niños [2]) y poco accesibles debido a la necesidad de un laboratorio con personal especializado, como la polisomnografía [3]. En respuesta, el grupo de investigación en bioinstrumentación e ingeniería clínica (GIBIC) ha desarrollado el dispositivo *SmartBedding* para obtener, de manera no invasiva y cómoda, información sobre el sueño a partir de variables registradas por el dispositivo: presión del cuerpo sobre la sábana, movimiento del cuerpo, temperatura y sonido.

Dormir es un proceso biológico complejo que consiste en un estado activo de inconsciencia producido por el cuerpo mientras el cerebro se encuentra en reposo [4]. En una noche de sueño se reconocen dos estados: movimiento rápido de ojos (REM, del inglés *rapid eye movement*) y no movimiento rápido de ojos (NREM), los cuales se alternan de manera cíclica durante un ciclo de sueño, iniciando en REM y pasando progresivamente a los estados de sueño profundo NREM, que contiene las etapas N1, N2 y N3 [5, 6]. En el hipnograma de la Figura 1 se presenta este comportamiento cíclico nocturno de dos adultos con diferentes edades; donde se encuentra que, de manera general, una vez iniciado el sueño, éste casi siempre progresa por las etapas N1 a N3 del sueño NREM en 45 a 60 min. La etapa N3 del sueño NREM (también llamada sueño de ondas lentas) predomina en el primer tercio de la noche y comprende 15-25 % del tiempo total de sueño nocturno en los adultos jóvenes. El primer episodio de sueño REM casi siempre ocurre en la segunda hora de sueño. El sueño NREM y REM se alternan durante la noche, con un periodo promedio de 90 a 110 min (el ciclo de sueño “ultradiano”). En total, en el adulto joven sano, el sueño REM constituye 20-25 % del tiempo total de sueño y las etapas N1 y N2 del sueño NREM constituyen 50-60 % [7].

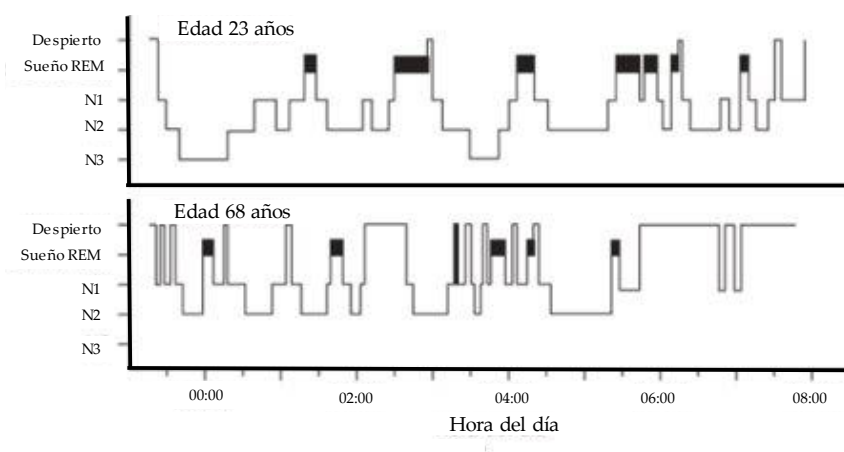


Figura 1: Hipnograma con la estructura de la vigilia - sueño para un joven y un anciano, presentando las tres etapas NREM (N1-N3) y sueño REM (barras oscuras). Tomado de [7].

Los registros del electroencefalograma (EEG) y oculograma (EOG) permiten el reconocimiento electrográfico de los cinco diferentes estados de vigilia y sueño: vigilia (W), etapa 1 (N1), etapa 2 (N2), etapa 3 (N3) y sueño REM. Para esto, cada una de las etapas se encuentra completamente caracterizada según los biopotenciales de los registros mencionados [3].

2. Objetivo de predicción

Se pretende usar las señales de presión y movimiento en cama, temperatura y sonidos para predecir las cuatro etapas del sueño básicas: estado despierto, vigilia, sueño REM y NREM. Para esto, se capturarán las señales de la sábana inteligente *SmartBedding* y se etiquetarán los datos usando información derivada de señales electroencefalográficas (el comportamiento de la señal difiere según la etapa de sueño en la que se encuentra un sujeto, lo cual se encuentra bien caracterizado en la literatura). En la Figura 2 se ilustra el proceso de predicción.

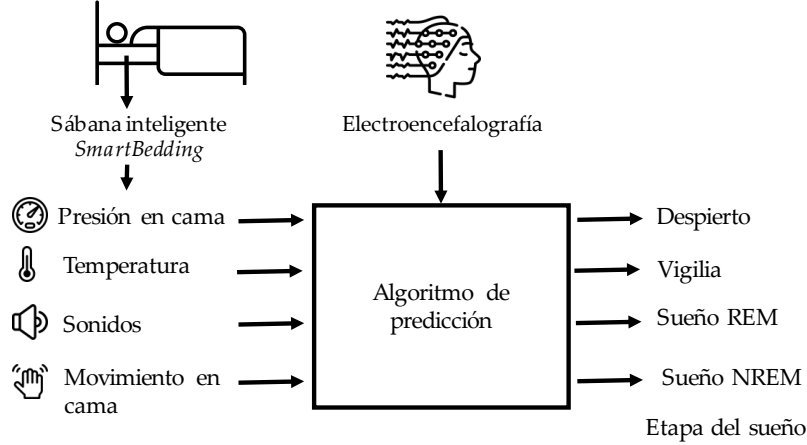


Figura 2: Esquema de predicción de etapas de sueño a partir de datos obtenidos con *SmartBedding*.

3. Dataset

En la Tabla 1 se presentan las características de los tipos de datos de entrada. Para tener un set de datos completo con el que se puedan usar algoritmos de Machine y Deep learning, se registrarán las señales para al menos 3 voluntarios durante una noche completa de sueño. Esto resulta ser suficiente porque, al tratarse de un proceso cíclico, se puede tener un etiquetado grande de datos a partir de la información derivada de las señales electroencefalográficas tras una noche completa de registro.

Tabla 1: Descripción de los datos de entrada al modelo.

Señal	Tipo de dato	Periodo / frecuencia de muestreo	Tamaño en disco
Presión en cama	Matriz 12x16 uint16	1s	384 bytes
Movimiento	Matriz 3x3 float	50ms	36 bytes
Temperatura	Vector float	1 min	4 bytes/min
Sonido	2 columnas tipo Char	44100 Hz	352.8 kBytes / s

4. Métricas de desempeño

De acuerdo a las características del proyecto, se propone el porcentaje de ajuste como métrica para evaluar el nivel de desempeño del modelo; el cual se espera que supere o iguale el 75 %. Además, investigaciones previas como [8] y [9], usan el porcentaje de sensibilidad y especificidad como apoyo para determinar la capacidad de predicción del algoritmo.

Los resultados de este proyecto serán la base para un estudio de predicción de calidad del sueño que será integrado en la sábana inteligente *Smartbedding*. Con este dispositivo los usuarios podrán monitorear, de manera ágil, accesible y cómoda, su noche de sueño usando una aplicación para celular que se conecta con la sábana. Dado el impacto que acarrea proporcionar datos que sean usados para diagnóstico sobre la calidad de una noche de sueño, las métricas de negocio deben superar el 80 % de ajuste; de manera que los resultados sean atractivos para el mercado.

5. Resultados previos

Actualmente se han venido implementando algoritmos con estrategias vanguardistas a partir de señales anatómicas. En la Tabla 2 se compara la metodología adoptada por cuatro estudios recientes para extraer características de señales electroencefalográficas para predicción de la calidad del sueño.

Tabla 2: Estudios que usan técnicas de inteligencia artificial para predicción de estados de sueño.

Referencia del estudio	[10]	[11]	[12]	[13]
Año	2021	2016	2010	2022
Adquisición de datos	Base de datos: National Sleep Research Resource	PSG de la base de datos: Sleep-EDF	En laboratorio del sueño usando PSG	Base de datos recolectada del centro médico Haaglanden
Preprocesado	(a) Filtrado interferencia de alta frecuencia, (b) División de datos en 30 s, (c) Eliminación de desviación de línea base, (d) Eliminación artefactos	(a) Descomposición en bandas usando filtrado pasabanda, (b) División de datos en 10 s	(a) Filtrado: EEG pasabanda 0.3 Hz-50 Hz, EOG Butterworth 40 y 400 Hz, (b) División de datos en 5 s	(a) Filtrado 60 Hz y pasabanda 0.5 - 44 Hz, (b) Eliminación y separación de artefactos producidos por movimiento ocular y muscular
Extracción de características	Transformada discreta Wavelet para obtener 4 componentes frecuenciales	(a) Distancia entre punto máximo y mínimo cada 100 muestras, (b) Energía y velocidad de la señal	Los parámetros de entrada son las señales de EEG, EOG derecho e izquierdo y EMG	(a) Características frecuenciales obtenidas con FFT, (b) PSD calculado para cada época con periodograma de Welch - se obtuvo para cada época potencia media, frecuencia media, máxima y mediana, y borde espectral, (c) Prueba F ANOVA para selección de característica según relevancia
Clasificador	Máquina de soporte vectorial	Máquina de soporte vectorial, árboles de decisión, redes neuronales, Nearest Neighbor, K-Nearest Neighbor, Linear Discriminant Analysis y Naive Bayes.	Red neuronal artificial	Modelo de red neuronal, modelo Detector automático de interacción chi-cuadrado, modelo supervisado C5.0
Resultado obtenido	Etapas del sueño	Etapas del sueño	Etapas del sueño	Etapas del sueño

6. Referencias

- [1] V. K. Chattu, M. D. Manzar, S. Kumary, D. Burman, D. W. Spence, and S. R. Pandi-Perumal, "The global problem of insufficient sleep and its serious public health implications," *Healthcare (Basel)*, vol. 7, p. 1, Dec. 2018.
- [2] N. Scalzitti, S. Hansen, S. Maturo, J. Lospinoso, and P. O'Connor, "Comparison of home sleep apnea testing versus laboratory polysomnography for the diagnosis of obstructive sleep apnea in children," *Int. J. Pediatr. Otorhinolaryngol.*, vol. 100, pp. 44–51, Sept. 2017.

- [3] J. V. Rundo and R. Downey, 3rd, “Polysomnography,” *Handb. Clin. Neurol.*, vol. 160, pp. 381–392, 2019.
- [4] J. E. Brinkman, V. Reddy, and S. Sharma, “Physiology of sleep,” in *StatPearls*, Treasure Island (FL): StatPearls Publishing, Jan. 2022.
- [5] M. Pedemonte and R. A. Velluti, *La vigilia y el sueño*. New York, NY: McGraw-Hill Education, 2020.
- [6] O. Mecarelli and E. Vicenzini, *Cerebrovascular Diseases*, pp. 633–645. Cham: Springer International Publishing, 2019.
- [7] T. E. Scammell, C. B. Saper, and C. A. Czeisler, *Trastornos del sueño*. New York, NY: McGraw-Hill Education, 2018.
- [8] F. Setiawan and C.-W. Lin, “A deep learning framework for automatic sleep apnea classification based on empirical mode decomposition derived from single-lead electrocardiogram,” *Life (Basel)*, vol. 12, Sept. 2022.
- [9] P. An, Z. Yuan, J. Zhao, X. Jiang, and B. Du, “An effective multi-model fusion method for EEG-based sleep stage classification,” *Knowl. Based Syst.*, vol. 219, p. 106890, May 2021.
- [10] W. Wen, “Sleep quality detection based on eeg signals using transfer support vector machine algorithm,” *Frontiers in Neuroscience*, vol. 15, 2021.
- [11] K. A. I. Aboalayon, M. Faezipour, W. S. Almuhammadi, and S. Moslehpour, “Sleep stage classification using eeg signal analysis: A comprehensive survey and new investigation,” *Entropy*, vol. 18, no. 9, 2016.
- [12] M. E. Tagluk, N. Sezgin, and M. Akin, “Estimation of sleep stages by an artificial neural network employing EEG, EMG and EOG,” *J. Med. Syst.*, vol. 34, pp. 717–725, Aug. 2010.
- [13] I. Hussain, M. A. Hossain, R. Jany, M. A. Bari, M. Uddin, A. R. M. Kamal, Y. Ku, and J.-S. Kim, “Quantitative evaluation of eeg-biomarkers for prediction of sleep stages,” *Sensors*, vol. 22, no. 8, 2022.